Data Analytics for Business 2024

MID EXAM

Anggota Kelompok

1.	Deni Apriadi	KM-CS12474
2.	Bernadet Bekania Telaumbanua	KM-CS12012
3.	Fatimah Ananda Permadani Hsg	KM-CS12369

BAB I
Pendahuluan

1.1 Latar belakang masalah (14 pts)

Tingginya angka pembatalan pemesanan pada industri perhotelan, khususnya pada kategori City Hotel, telah menjadi isu yang signifikan dalam beberapa tahun terakhir. Pembatalan tidak hanya berdampak pada pendapatan hotel tetapi juga pada efisiensi operasional dan alokasi sumber daya. Data yang ada menunjukkan bahwa pembatalan sering kali dikaitkan dengan permintaan khusus yang tidak terpenuhi atau kurang memuaskan, dengan jumlah pembatalan yang meningkat seiring bertambahnya total permintaan khusus. Penelitian ini bertujuan untuk menganalisis faktor-faktor utama yang mempengaruhi tingkat pembatalan pesanan hotel, menggunakan proses pengolahan data dan analisis SQL serta Python. Melalui penelitian ini, diharapkan dapat diidentifikasi pola yang mendasari tingkat pembatalan yang tinggi serta memberikan solusi berbasis data untuk meningkatkan kualitas layanan dan meminimalkan angka pembatalan, sehingga dapat memberikan manfaat bagi bisnis perhotelan dan meningkatkan kepuasan pelanggan.

BAB II
Business Process Analysis

2.1 Identifikasi Masalah

Berikut identifikasi tahapan proses Inisiasi Pemesanan oleh pelanggan > Alokasi Kamar dan Pemrosesan Permintaan Khusus di Sistem Reservasi > Proses Pembayaran melalui Departemen Pembayaran > Konfirmasi Pemesanan dan Pemberian Informasi > Check-In oleh pelanggan > Pengalaman Menginap dan Pemenuhan Permintaan Khusus > Check-Out dan penyelesaian proses.

Analisa masalah yang terjadi adalan Pembatalan pesanan yang terjadi paling banyak terjadi pada City Hotel, yaitu terjadi pembatalan 19628 pesanan. Berdasarkan hasil tersebut dapat diidentifikasi kemungkinan pembatalan terjadi karena *special request* yang tidak dipenuhi atau kurang memuaskan dari pihak hotel karena semakin banyak sum of total sepecial request maka semakin tinggi pula tingkat pembatalannya. Data pembatalan dapat dilihat pada Tabel 1.

Tabel 1. Persentase Pembatalan Pesanan

Hotel	Category Leadtime	SUM of total_of_special_requests	SUM of is_canceled	COUNT of is_canceled
City Hotel	Panjang	25687	19628	39174
	Pendek	22695	11120	32789
	Sedang	5712	2354	7367
Resort Hotel	Panjang	13106	6396	17298
	Pendek	13602	3869	19069
	Sedang	2865	857	3693

2.2 Diagram BPMN

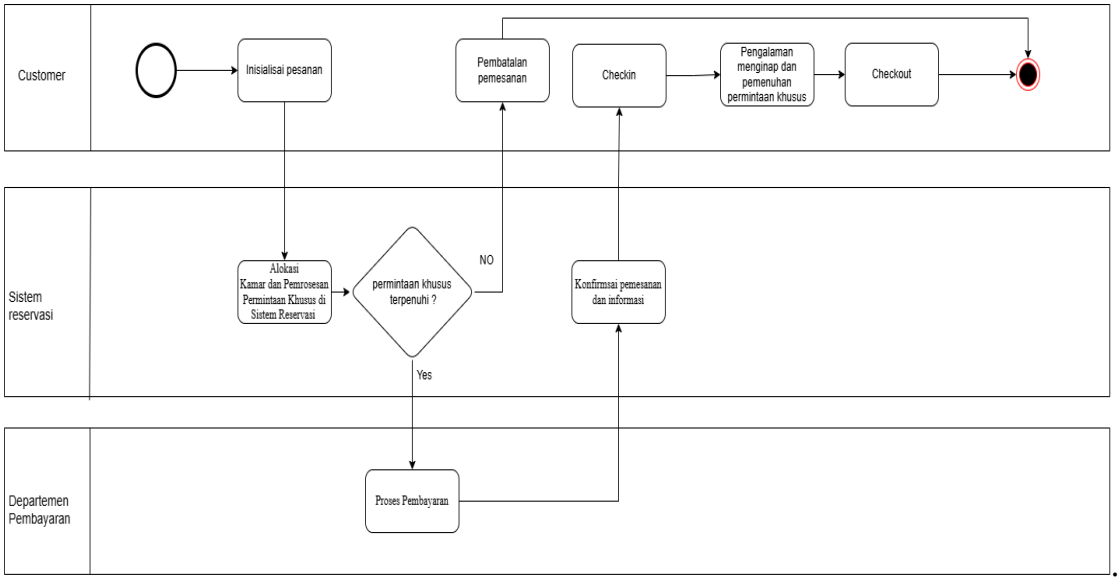

Penjelasan untuk BPMN, proses dimuali dari inisialisasi pemesanan selanjutnya alokasi kamar dan permintaan khusus, jika permintaan khusus tidak terpenuhi maka kemungkinan besar pemesanan akan dibatalkan disinilah masalah yang sering terjadi pada pembatalan pemesanan hotel, selanjutnya jika permintaan khusus terpenuhi maka akan melanjutkan ke proses pembayaran lalu sistem akan mengkonfirmasi pemesanan selanjutnya customer akan checkin, lalu customer akan mamberikan ulsan dan check out.

BAB III
Data Preparation and Structured Query Language

3.1 Data Preparation

Sebelum data digunakan untuk analisis terlebih dulu data perlu dibersihkan, pertama lakukan cek data yang ada, apakah terdapat *missing value* atau tidak. Jika terdapat *missing value* contoh seperti data kosong maka kita pastikan kembali apakah data tersebut akan dihapus atau di isi dengan nilai lainnya seperti *mean, mode, min,* atau *max*. Untuk lebih jelasnya dapat dilihat pada Gambar 2.

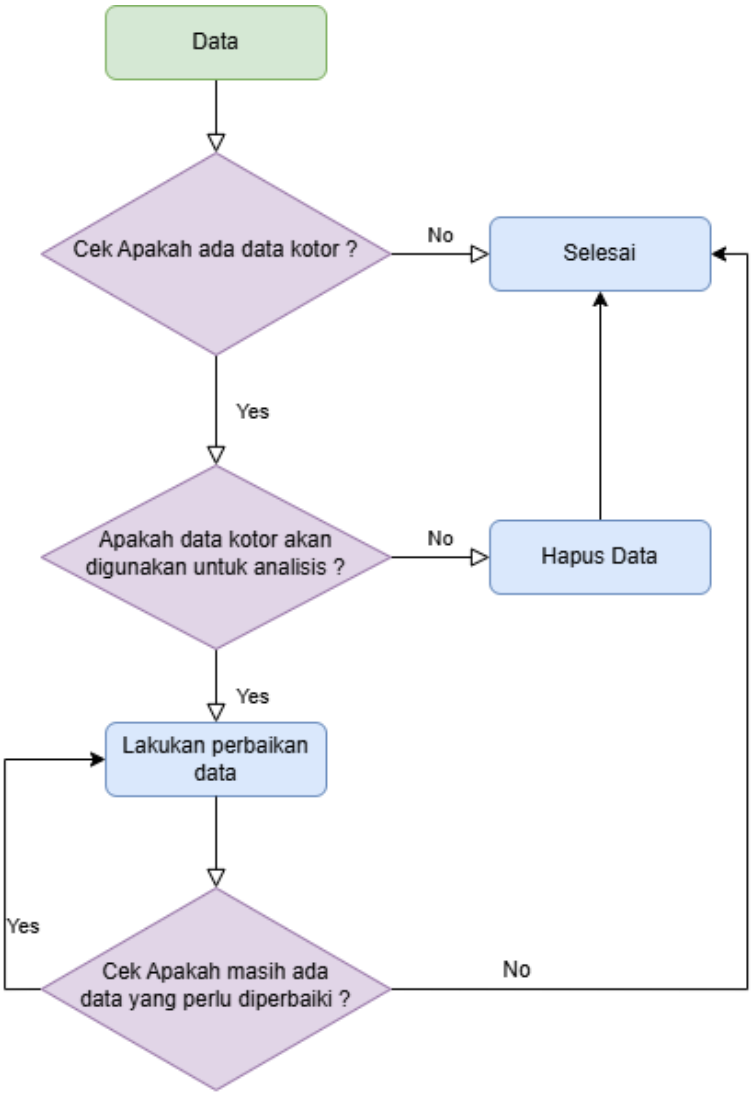

Gambar 2. *Flow data preparation.*

Kode program data cleansing dapat dilihat pada Kode Program 2.

Kode Program 2. Proses *data cleansing* pada Python.

```
from google.colab import drive
drive.mount('/content/drive/')
import pandas as pd
df = pd.read_csv("/content/drive/MyDrive/Midtrem/midterm_hotel_data.csv")
# convert tipe data agar sesuai
df = df.convert_dtypes()
# Menghitung missing values
print(df.isnull().sum())
# Menghapus baris dengan missing value
df_cleaned = df.drop(columns='company')
# Mengisi missing values
df_cleaned.fillna({"lead_time":df_cleaned["lead_time"].median(),
                   "stays_in_weekend_nights":df_cleaned["stays_in_weekend_nights"].median(),
                   "adults":df_cleaned["adults"].median(),
                   "adr":df_cleaned["adr"].median(),
                   "country":df_cleaned["country"].mode()[0],
                   "total_of_special_requests":0,
                   "agent":0,
                   "children":0,
                   },inplace=True)
# cek data setelah dibersihkan
print(df_cleaned.isnull().sum())
```

Penjelasan kode:

- conect google colab dan google drive tempat kita menyimpan data
- import pandas dengan alisa pd
- lalu tampilkan data frame melalui alamat path yang tersedia
- lalu konvert tipe data agar sesuai dengan data
- cek missing value jika ada maka pastikan apakah kolom yang terdapat missing value akan digunakan untuk analisis jika iya maka lakukan prose claning jika tidak maka kolom bisa dihapus.
- Setelah dicek terdapat beberapa kolom yang null yang akan digunakan untuk analisis maka kita akan membersihkan atau mempierbaiki data tersebut. Dan ada juga kolom null yang tidak akan digunakan untuk analisis maka kita hapus saja.
- Setelah selesai perbaikan cek kembali apakah masih ada missing value.

3.2 Data Extraction

3.2.1 Menghitung Tingkat Pembatalan Reservasi untuk Setiap Jenis Hotel Berdasarkan Tahun.

Dari hasil perhitungan menggukan SQL kami mendapat nilai sebagai berikut, tinkat pembatal paling tinggi terjadi pada City Hotel tahun 2015 yaitu 43,88% pematalan, lalu yang ke dua City Hotel tahun 2017 yaitu, 42,5% pembatalan, di posisi ke tiga City Hotel tahun 2016 yaitu, 40,4% pembatalan, posisi ke empat Resort hotel tahun 2017 yaitu, 30,76%, selanjutnya Resort Hotel tahun 2016 yaitu, 26,55% dan terakhir resort hotel tahun 2015 yaitu, 25,75%. Untuk lampiran *query* yang digunakan, bisa dilihat pada potongan Kode Program 1 berikut:

Kode Program 1. Tingkat Pembatalan Reservasi Berdasarkan Tahun.

```
SELECT
    hotel,
    arrival_date_year,
    ROUND(SUM(is_canceled) * 100.0 / COUNT(*), 2) AS cancellation_rate
FROM
    hotel_data hd
GROUP BY
    hotel,
    arrival_date_year;
```

Penjelasan kode:

- Ambil kolom hotel dan tahun kedatangan lalu jalankan fungsi round untuk mendapatkan penjumlahan pesanan yang dibatalkan dalam bentuk persentase dan dialiaskan sebagai rateing pembatalan dari tabel hotel data dan di gruping berdasarkan hotel. Hasil query dapat dilihat pada gambar 3.1.

hotel	arrival_date_year	cancellation_rate
City Hotel	2,015	43.88
City Hotel	2,016	40.4
City Hotel	2,017	42.5
Resort Hotel	2,015	25.72
Resort Hotel	2,016	26.55
Resort Hotel	2,017	30.76

Gambar 3.1. Tingkat Pembatalan Reservasi Berdasarkan Tahun.

3.2.2 Menghitung Rata-Rata Waktu Tunggu Sebelum Check-In untuk Setiap Kelompok Permintaan Khusus

Rata-rata waktu tunggu sebelum check-in untuk setiap kelompok permintaan khusus

- Tanpa permintaan rata-rata waktu tunggu adalah 210,77

- Permintaan khusus (1) rata-rata waktu tunggu adalah 190,41
- Permintaan khusus (2) rata-rata waktu tunggu adalah 182,47
- Permintaan khusus (3) rata-rata waktu tunggu adalah 181,8
- Permintaan khusus (4) rata-rata waktu tunggu adalah 197,04
- Permintaan khusus (5) rata-rata waktu tunggu adalah 171,55

Untuk lampiran *query* yang digunakan, bisa dilihat pada potongan Kode Program 2 berikut:

Kode Program 2. Rata-Rata Waktu Tunggu Sebelum *Check-In* untuk Setiap Kelompok Permintaan Khusus

```
WITH above_average_lead_time AS (
 SELECT
     lead_time,
     total_of_special_requests
 FROM
     hotel_data
 WHERE
     lead_time > (SELECT AVG(lead_time) FROM hotel_data)
)
SELECT
    total_of_special_requests,
    ROUND(AVG(lead_time), 2) AS average_lead_time
FROM
    above_average_lead_time
GROUP BY
    total_of_special_requests;
```

Penjelasan kode:

- Membuat CTE atau tabel bayangan dengan nama rata rata lead time dari kolom lead time dan total permintaan spesial dari tabel hotel data, dimana leadtime lebih besar daripada rata rata lead time.
- Panggil kolom permintaan spesial dan jalankan fungsi round mencari rata rata leadtime dengan menampilkan 2 angka setelah koma lalu dialiaskan sebagai rata-rata leadtime, dari tabel bayangan yang dibuat sebelumnya dan di group by total permintaan khusus. Hasil dapat dilihat pada gambar 2.2.

total_of_special_requests	average_lead_time
0	210.77
1	190.41
2	182.47
3	181.8
4	197.04
5	171.55

Gamabr 2.2. Rata-Rata Waktu Tunggu Sebelum *Check-In* untuk Setiap Kelompok Permintaan Khusus

3.2.3 Menemukan Tanggal Reservasi dengan Pendapatan Tertinggi Berdasarkan Rata-Rata Tarif Harian (ADR)

Tanggal Reservasi dengan pedapatan tertinggi terjadi pada tanggal 17 Agustus 2017 dengan total pendapatan 3036,86 real. Untuk lampiran *query* yang digunakan, bisa dilihat pada potongan Kode Program 3 berikut:

Kode Program 3. Tanggal Reservasi dengan Pendapatan Tertinggi Berdasarkan Rata-Rata Tarif Harian (ADR)

```
SELECT
    reservation_status_date,
    ROUND(SUM(adr), 2) AS total_revenue
FROM
    hotel_data hd
WHERE
    reservation_status = 'Check-Out'
    AND total_of_special_requests > 2
GROUP BY
    reservation_status_date
ORDER BY
    total_revenue DESC
LIMIT 1;
```

Penjelasan kode:

- Ambil tanggal status reservasi lalu round menjumlahkan adr dengan penulisan 2 angka setelah koma dialiaskan sebagai total revenue, dari data frame yang sudah dibersihkan

dimana statues reservasi check out dan total special request lebih dari 2. Lalu digroup by berdasarkan tanggan status reservasi dan order by revenue diurutkan dari niali yang paling besar, dan hanya menampilkan 1 data awal saja.

Hasil dapat dilihat pada gambar 3.3

reservation_status_date	total_revenue
2017-08-17	3,036.86

Gambar 3.3. Tanggal Reservasi dengan Pendapatan Tertinggi Berdasarkan Rata-Rata Tarif Harian (ADR)

3.2.4 Menganalisis Hubungan Antara Lead Time dan Nilai ADR

Lead time dan niai adr tidak memiliki hubunganyang signifikan dapat dilihat dari hasil analisis berikut:

- Lead tima 0-30 hari memiliki rata-rata pendapat 97.65
- Lead tima 31-60 hari memiliki rata-rata pendapat 103,33
- Lead tima 61-90 hari memiliki rata-rata pendapat 100,74
- Lead tima 90+ hari memiliki rata-rata pendapat 99,39

Untuk lampiran *query* yang digunakan, bisa dilihat pada potongan Kode Program 4 berikut:

Kode Program 4. Menganalisis Hubungan Antara *Lead Time* dan Nilai *ADR*

```
WITH lead_time_ranges AS (
    SELECT
        CASE
            WHEN lead_time BETWEEN 0 AND 30 THEN '0-30 hari'
            WHEN lead_time BETWEEN 31 AND 60 THEN '31-60 hari'
            WHEN lead_time BETWEEN 61 AND 90 THEN '61-90 hari'
            WHEN lead_time > 90 THEN '90+ hari'
        END AS lead_time_range,
        adr
    FROM
        hotel_data
)
SELECT
    lead_time_range,
    ROUND(AVG(adr), 2) AS average_adr
FROM
    lead_time_ranges
GROUP BY
    lead_time_range;
```

Penjelasan kode:

- Membuat CTE atau tabel bayangan dengan case leadtime antara 0 sampai 30, 31 sampai 60 hari, 61-90 hari dan 90 hari lebih lalu dialiaskan dengan lead time range.
- Ambil data dari table CTE yaitu leadtime range lalu dibulatkan rata-rata pendpatan dimana 2 angka dibelakang koma lalu dialiaskan menjadi Average adr
- Lalu di group by leadtime range.

Visualisasi data dapat dilihat pada gambar 3.4

	lead_time_range	average_adr
1	0-30 hari	97.65
2	31-60 hari	103.33
3	61-90 hari	100.74
4	90+ hari	99.39

Gambar 3.4. Menganalisis Hubungan Antara *Lead Time* dan Nilai *ADR*

BAB IV
Python Programming

4.1 Exploratory Data Analysis

4.1.1 Bagaimana rasio antara lead_time dengan jumlah hari reservasi dibatalkan (is_canceled==1)

Jawaban: Dari hasil visualisasi data menggunakan scatterplot diatas dapat disimpulkan bahwa antara pembatalan dan leadtime tidak ada korelasi atau hubungan karena nilai nya sangat kecil atau mendekati 0 yaitu 0,24. Kode dapat dilihat pada table 4.1 berikut:

Tabel 4.1

```
1.  canceled_data = df_cleaned[df_cleaned['is_canceled'] == 1]
2.  plt.figure(figsize=(10, 6),
3.  sns.scatterplot(x='lead_time', y='is_canceled', data=df_cleaned)
4.  plt.title('Rasio Lead Time dengan Jumlah Reservasi Dibatalkan')
5.  plt.xlabel('Lead Time (hari)')
6.  plt.ylabel('Status Pembatalan')
7.  plt.show()correlation = df_cleaned['lead_time'].corr(df_cleaned['is_canceled'])
8.  print (f"Nilai korelasi antara lead_time dan is_canceled: {correlation:.2f}")
```

Penjelasan kode:

- No 1. Memfilter data frame yang sudah dibersihkan berdasarkan pesanan yang dibatalkan
- No 2. Membuat kanvas untuk visualisasi data
- No 3. Mambuat scatter plot dengan seaborn dimana sumbu x adalah leadtime dan sumbu y adalah pesanan dibatalkan, dari data yang sudah dibersihkan
- No 4. Judul chart
- No 5. Nama sumbu x
- No 6. Nama sumbu y
- No 7. Menampilkan chart
- No 8. Mencari nilai korelasi menggunakan fungsi corr
- No 9. Menampilkan hasil korelasi

Tampilan visualisasi data dapat dilihat pada gambar 4.1 berikut:

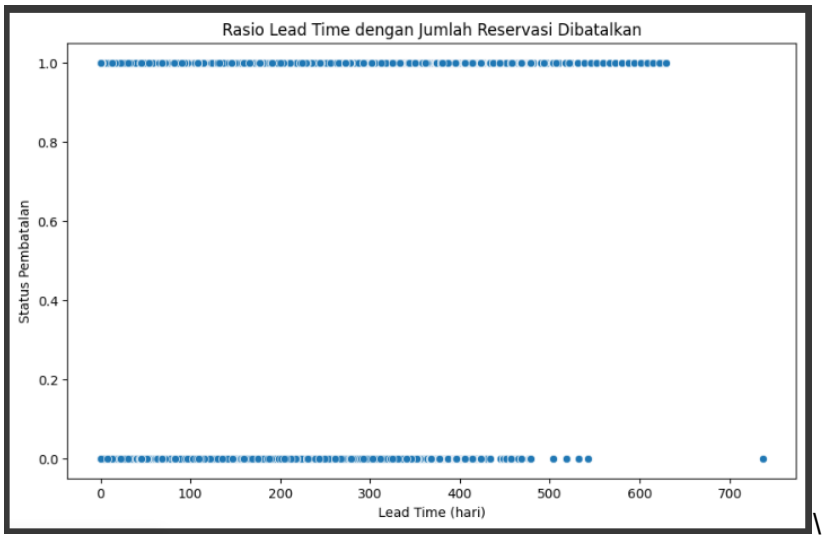

Gambar 4.1. *Scatter plot*

4.1.2 Pola Pendapatan Antara Resort Hotel dan City Hotel

Jawaban: Dari data visualisasi yang ditampilkan pola pendapatan unutk City Hotel bisa dikatakan stabil dibandingkan dengan resot hotel yang mengalami kenaikan dan penurunan pendapatan yang cukup signifikan terutama pada bulan agustus. Kode dapat dilihat pada tabel 4.2 berikut:

```
1.  df_cleaned['arrival_date_month'] =
    pd.Categorical(df_cleaned['arrival_date_month'], categories=[
        'January', 'February', 'March', 'April', 'May', 'June', 'July',
        'August', 'September', 'October', 'November', 'December'], ordered=True)
2.  monthly_revenue =
    df_cleaned.groupby(['hotel','arrival_date_month'])['adr'].mean().reset_index()
3.  plt.figure(figsize=(12, 6))
4.  sns.lineplot(data=monthly_revenue, x='arrival_date_month', y='adr', hue='hotel')
5.  plt.title('Pola Pendapatan Bulanan Antara Resort Hotel dan City Hotel')
6.  plt.xlabel('Bulan')
7.  plt.ylabel('Pendapatan Rata-Rata (ADR)')
8.  plt.show()
```

Penjelasan kode:

- No 1. Mengkonfersi bulan menajdi urutal waktu menggunakan pd.categorical.

- No 2. Menghitung rata-rata ADR perbulan untuk tiap hotel
- No 3. Buat kanvas chart
- No 4. Buat line plot dengan seaborn dari data yang sudah dibuat pada kode no 1, sumbu x = bulan kedatangan dan y = pendapatan
- No 5. Judul chart
- No 6. Nama sumbu x
- No 7. Nama sumbu y
- No 8. Menampilkan chart

Chart dapat dilihat pada gambar 4.2

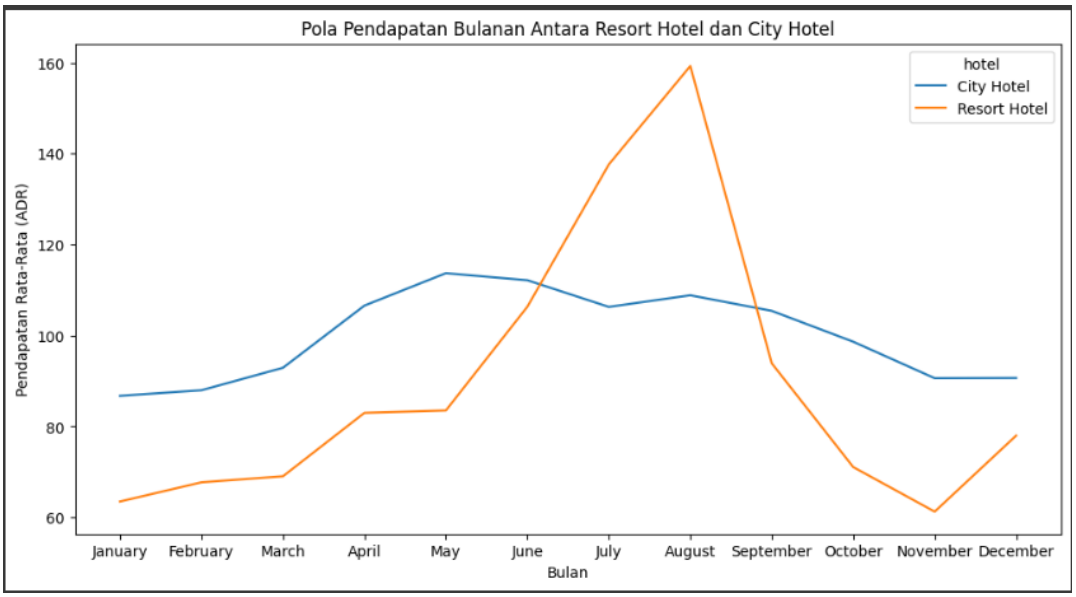

Gambar 4.2. Pola Pendapatan Antara *Resort Hotel* dan *City Hotel*

4.1.3 Negara yang Paling Sering Membatalkan Reservasi

Jawaban: Dari visualisasi data yang ditampilkan dapat diketahui bahwa tingkat pembatalan tertinggi berasal dari negara prancis dari baik dari city hotel maupun resort hotel. Kode dapat dilihat pada table 4.3.

Table 4.3. Negara Paling Sering Membatalkan Reservasi

```
1.  cancel_by_country = df_cleaned[df_cleaned['is_canceled'] ==
    1].groupby(['country', 'hotel']).size().reset_index(name='cancel_count')
2.  top_countries = cancel_by_country.sort_values(by='cancel_count',
    ascending=False).head(10)
3.  plt.figure(figsize=(12, 6))
4.  sns.barplot(data=top_countries, x='country', y='cancel_count',
    hue='hotel') # buat barplot dengan seaborn dari data top countris, dengan
    sumbu x = country dan sumbu y = canel count, dipisahkan berdasarkan hotel
5.  plt.title('Negara dengan Pembatalan Reservasi Tertinggi')
6.  plt.xlabel('Negara')
7.  plt.ylabel('Jumlah Pembatalan')
8.  plt.show()
```

Penjelasan kode:

- No 1. Memfilter data berdasarkan pesanan yang dibatalkan lalu di grup kan berdasarkan negara dan jenis hotel
- No 2. Mengurutkan data berdasarkan count terbesar
- No 3. Buat kanvas untuk bar plot
- No 4. Buat bar plot dengan seaborn
- No 5. Judul chart
- No 6. Nama sumbu x
- No 7. Nama sumbu y
- No 8. Menampilkan chart

Visualisasi data dapat dilihat pada gambar 4.3.

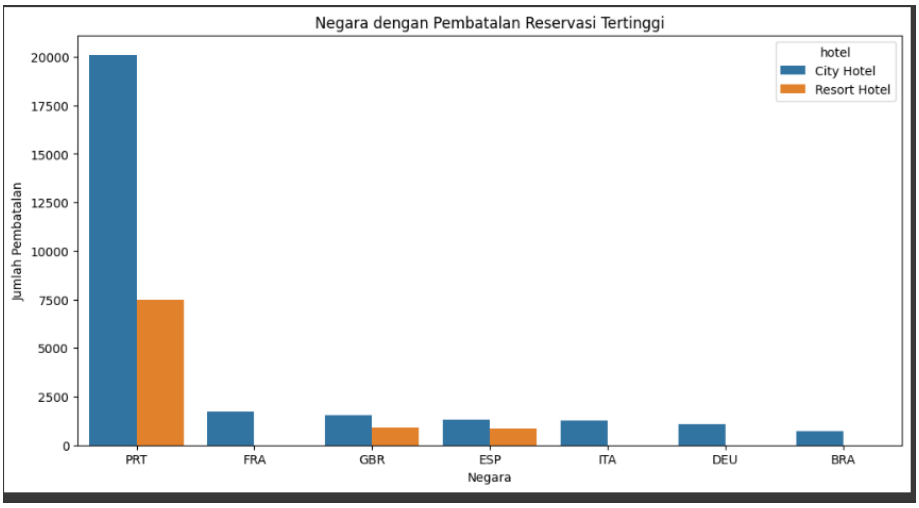

Gambar 4.3. Negara dengan Pembatalan Reservasi Tertinggi

4.1.4 Analisis Perilaku Pemesanan Last-Minute

Jawaban: dari data yang dvisualisasikan bahwa rasio pembatalan pesanan dengan kateggori last minutes cukup rendah, bisa disimpulkan perilaku pemesanan last-Minute berperilaku baik. Kode bisa dilihat pada table 4.4

Table 4.4. Analisis Perilaku Pemesanan *Last-Minute*

```
1. df_cleaned['is_last_minute'] = df_cleaned['lead_time'] <= 7
2. last_minute_cancellation =
   df_cleaned[df_cleaned['is_last_minute']].groupby('is_canceled').size()
3. plt.figure(figsize=(6, 6))
4. last_minute_cancellation.plot(kind='pie', labels=['Tidak Dibatalkan',
   'Dibatalkan'], autopct='%1.1f%%')
5. plt.title('Rasio Pembatalan Pemesanan Last-Minute')
6. plt.show()
```

Penjelasan kode:

- No 1. Menambahkan kolom las minute dimana lead time < 7 hari masuk kedalam category tersebut
- No 2. Fiter data hanya menampilkan data yang masuk kategori last minute lalu di grup berdasarkan pensanan yang dibatalkan.
- No 3. Buat kanvas chart

- No4. Buat chart Pie
- No 5. Judul pie chart
- No 6. Tampilkan pie chart

Gambar visualisasi bisa dilihat pada gamabr 4.4

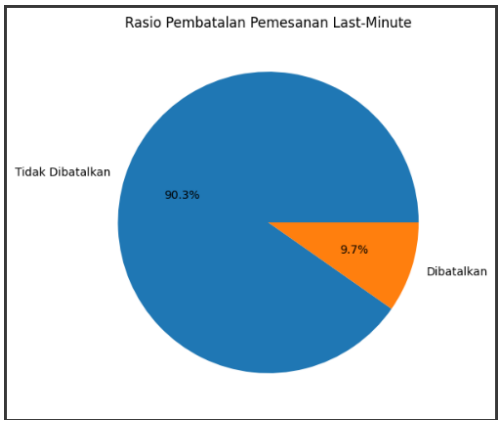

Gambar 4.4. Analisis Perilaku Pemesanan *Last-Minute*

```
1. from scipy import stats
2. t_stat, p_value = stats.ttest_ind(data_adr_city, data_adr_resort)
3. print(f"T-Statistic: {t_stat:.2f}")
4. print(f"P-Value: {p_value:.2f}")
```

5 A/B Testing (14 pts)

Hasil pengujian A/B Testing yang dilakukan medapatkan hasil bahwa nilai p lebih kecil dari 0,05 sehingga dapat disimpulkan bahwa terdapt perbedaan signifikan antara ADR resort hotel dan city hotel. Kode dapat dilihat pada tabel 5.1 berikut:

Kode Program 5.1. *A/B Testing*

Penjelasan kode:

- Baris ke satu import modul scipy.stats
- Baris ke 3 melakukan two tes sample t-test yang bertujuan untuk membandingkan apakah ada perbedaan reta-rata yang signifikan antara dua kelompok (dalam hal ini ADR city hotel dan resort hotel).
- Baris ke 5 menampilkan hasil sample t-tes untuk nilai t_stat diambil 2 angka setelah koma
- Baris ke 6 menampilkan hasil p_value diambil 2 angka satelah koma.

Hasilnya dapat dilihat pada gambar 5.1 berikut**:**

```
T-Statistic: 29.29
P-Value: 0.00
```

Gambar 5.1. *A/B Testing*

BAB V
Kesimpulan & Saran

A. Kesimpulan utama

Hasil analisis menunjukkan bahwa tingginya tingkat pembatalan pesanan pada City Hotel kemungkinan besar disebabkan oleh tidak terpenuhinya permintaan khusus pelanggan. Dengan meningkatnya permintaan khusus yang tidak dipenuhi, tingkat pembatalan juga semakin tinggi. Temuan ini memberikan kontribusi bagi bidang ilmu pengetahuan dalam analisis data dan penerapan teknologi pemrosesan permintaan khusus untuk meningkatkan kepuasan pelanggan. Secara bisnis, hasil ini membantu manajemen hotel mengidentifikasi area kritis yang memerlukan perbaikan layanan dan menyesuaikan strategi pemasaran serta pengelolaan sumber daya sesuai kebutuhan pelanggan.

B. Saran untuk penelitian selanjutnya

Penelitian lanjutan dapat difokuskan pada analisis per faktor untuk memahami faktor-faktor yang paling memengaruhi pembatalan. Selain itu, penggunaan metode machine learning dapat dilakukan untuk memprediksi tingkat pembatalan berdasarkan data permintaan khusus, kategori hotel, dan faktor lainnya. Memperluas penelitian ini ke hotel-hotel lainnya dan memasukkan data sentimen dari ulasan pelanggan online juga dapat memberikan wawasan yang lebih komprehensif.

BAB VI
Lampiran

A. Online Diagram

Silahkan lampirkan link Online Diagram Tools anda disini.

https://drive.google.com/file/d/1cgqr73w0sVNO8Fwttd2yYubtVGFnPZVR/view?usp=sharing

https://docs.google.com/spreadsheets/d/17j8HfFb69DIvODsodXqKuEjtofdjtZpS-uhWuVNa0ok/edit?usp=sharing

B. Python Code

Silahkan lampirkan link Google Colab anda disini.

https://colab.research.google.com/drive/1jcvCsRaeSGi0VuWTgC3Jjzwf-fA4nr-m?usp=sharing

C. Recording

1. Link Recording

   Link Recording :

   https://youtu.be/E2sTykkhLPc?feature=shared